CRISP - DM

Ciências de Dados e Inteligência Artificial

PUC – SP

Prof. Eduardo Savino Gomes

The CRISP-DM Process Model

CRoss-Industry Standard Process for Data Mining

CRISP - DM

CRISP-DM, que significa Processo Padrão de Vários Segmentos de Mercados (Inter-Indústria) para Mineração de Dados, é uma forma comprovada pelo mercado para orientar seus esforços de mineração de dados. (Fonte:https://www.ibm.com/docs/pt-br/spss-modeler/18.4.0?topic=dm-crisp-help-overview)

CRISP-DM foi desenvolvido de forma que pode ser aplicado em qualquer tipo de Indústria ou segmento de mercado, por isso **Cr**oss-*I*ndustry.

- Metodologia padrão não proprietária que identifica as diferentes fases na implantação de um projeto de data mining (DMP).

- Como uma **metodologia**, ela inclui descrições das fases típicas de um projeto, as tarefas envolvidas em cada fase e uma explicação dos relacionamentos entre essas tarefas.

- Como um **modelo de processo**, o CRISP-DM fornece uma visão geral do ciclo de vida da mineração de dados.

CRISP - DM

Embora criada a mais de 20 anos, a metodologia CRISP-DM ainda é amplamente utilizada nos dias atuais, claro, com ajustes e melhorias, normalmente em função das diferenças entre as diversas áreas de negócios onde é aplicada e da evolução tecnológica.

Embora criada auxiliar projetos de Data Mining (Mineração de Dados) atualmente é utilizada em diversos projetos de Data Analytics e Data Science.

CRISP - DM

Metodologia

Metodologia propões 6 fases

- **Entender o Negócio**: foca em entender o objetivo do projeto a partir de uma perspectiva de negócios, definindo um plano preliminar para atingir os objetivos.
- **Entender os Dados**: recolhimento de dados e inicio de atividades para familiarização com os dados, identificando problemas ou conjuntos interessantes.
- **Preparação dos Dados**: construção do conjunto de dados final a partir dos dados iniciais. Normalmente ocorre várias vezes no processo.
- **Modelagem**: várias técnicas de modelagem são aplicadas, e seus parâmetros calibrados para otimização. Assim, é comum retornar à Preparação dos Dados durante essa fase.
- **Avaliação**: é construído um modelo que parece ter grande qualidade de uma perspectiva de análise de dados. No entanto, é necessário verificar se o modelo atinge os objetivos do negócio.
- **Implantação**: o conhecimento adquirido pelo modelo é organizado e apresentado de uma maneira que o cliente possa utilizar.

CRISP - DM

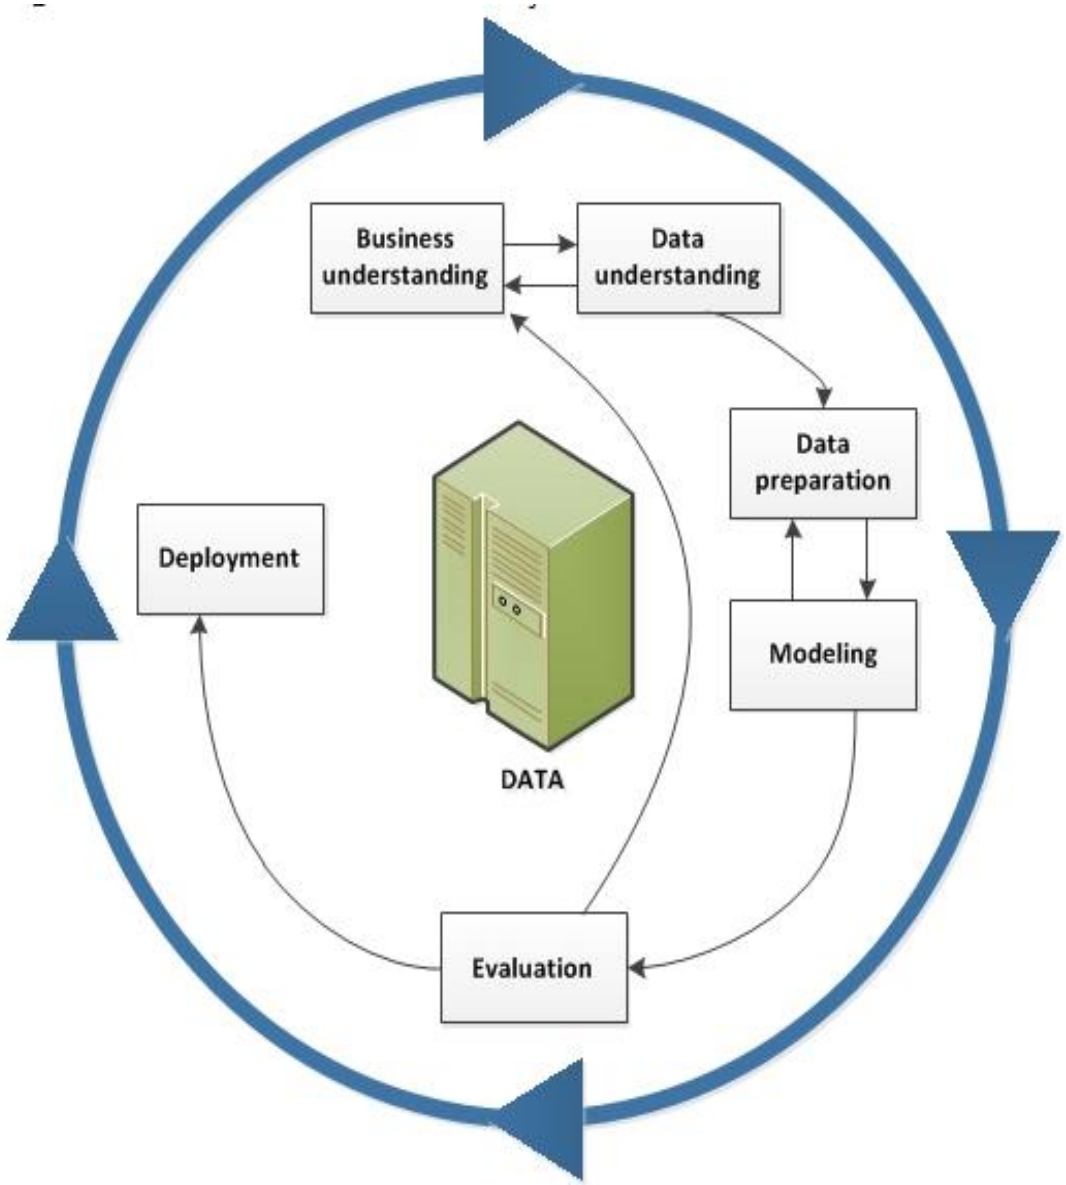

O modelo de ciclo de vida é composto de seis fases com setas indicando as dependências mais importantes e frequentes entre as fases. A sequência das fases não é rigorosa. De fato, a maioria dos projetos vão e voltam entre as fases, conforme necessário.

O modelo CRISP-DM é flexível e pode ser facilmente customizado. Por exemplo, seu grupo deseja verificar a relação entre clima e dados de plantio, é provável que sua equipe examine detalhadamente grandes quantidades de dados sem uma meta de modelagem específica. Em vez da modelagem, seu trabalho irá se concentrar na exploração e visualização de dados para descobrir os padrões e então tentar criar um modelo. O CRISP-DM permite que você crie um modelo de mineração de dados que se encaixe em suas necessidades específicas.

Em tal situação, as fases de modelagem, avaliação e implementação podem ser menos relevantes do que as fases de entendimento e preparação de dados. Entretanto, ainda é importante considerar algumas das questões levantadas durante essas fases posteriores para o planejamento de longo prazo e para futuras metas de mineração de dados.

https://www.ibm.com/docs/pt-br/SS3RA7_18.4.0/modeler_crispdm_ddita/clementine/images/crisp_process.jpg

CRISP - DM

Fases e Atividades

Entender o Negócio

- Determinar os Objetivos do Negócio
- Avaliar a Situação
- Determinar as Metas do Projeto
- Produzir um Planejamento do Projeto

Entender os Dados

- Coletar dados Iniciais
- Descrever os Dados
- Explorar os Dados
- Verificar a Qualidade dos Dados

Preparação dos Dados

- Selecionar os Dados
- Limpar/ Uniformizar os dados
- Derivar dados
- Integrar os Dados
- Formatar os Dados

Modelagem

- Selecionar a técnica de modelagem
- Gerar modelos de teste
- Construir o Modelo
- Avaliar o Modelo

Avaliação

- Avaliar os Resultados
- Processo de Revisão
- Definir os Próximos Passos

Implantação

- Implantação do Plano
- Plano de Monitoramento e Manutenções
- Produzir Relatório Final
- Revisão do Projeto

Entender o Negócio

Determinar os objetivos de negócios

- entender completamente, de uma perspectiva de negócios, o que o cliente realmente deseja realizar
- descobrir fatores importantes, no início, que podem influenciar o resultado do projeto
- negligenciar esta etapa é gastar muito esforço produzindo as respostas certas para as perguntas erradas

Avaliar a situação

- descoberta de fatos mais detalhada sobre todos os recursos, restrições, suposições e outros fatores que devem ser considerados
- detalhar os detalhes

Entender o Negócio

Determinar metas do projeto

- Uma meta de negócios declara objetivos na terminologia de negócios
- Uma meta de mineração de dados declara os objetivos do projeto em termos técnicos

Ex:

Objetivo do negócio: “Aumentar as vendas do catálogo para os clientes existentes.”

Objetivo do Projeto: “Prever quantos itens um cliente comprará, considerando suas compras nos últimos três anos, informações demográficas (idade, salário, cidade) e o preço do item”.

LEMBRE-SE: Projetos de TI devem estar alinhados com os Objetivos do Negócio

Entender o Negócio

Produzir um planejamento de projeto

- Descrever o plano pretendido para atingir as metas de mineração de dados e as metas de negócios
- O plano deve especificar o conjunto antecipado de etapas a serem executadas durante o restante do projeto, incluindo uma seleção inicial de ferramentas e técnicas

Entender os Dados

Coletar dados iniciais

- Adquirir dentro do projeto os dados listados nos recursos do projeto
- Incluir carregamento de dados, se necessário, para compreensão dos dados
- Possivelmente levar a etapas iniciais de preparação de dados
- Se adquirir várias fontes de dados, a integração é um problema adicional, aqui ou na fase posterior de preparação de dados

Descrever dados

- Examinar as propriedades "brutas" ou "superficiais" dos dados adquiridos
- Relatório sobre os resultados

Entender os Dados

Explorar dados

- Abordar as questões de mineração de dados, que podem ser abordadas usando consultas, visualização e relatórios, incluindo: distribuição de atributos-chave, resultados de agregações simples, relações entre pares ou pequenos números de atributos/propriedades de subpopulações significativas, análises estatísticas simples.
- Abordar diretamente os objetivos de mineração de dados
- Refinar a descrição de dados e relatórios de qualidade
- Alimentar a transformação e outras preparações de dados necessárias

Verificar a qualidade dos dados

Examinar a qualidade dos dados, abordando questões como: “Os dados estão completos?”, “Faltam valores nos dados?”, “Os valores são uniformes/comparáveis?”

Preparação dos Dados

Selecionar dados

- Decidir sobre os dados a serem usados para análise
- Os critérios incluem relevância para os objetivos de mineração de dados, qualidade e restrições técnicas, como limites de volume ou tipos de dados
- Abrange a seleção de atributos, bem como a seleção de registros em uma tabela

Limpar/Uniformizar os dados

Elevar a qualidade dos dados ao nível exigido pelas técnicas de análise selecionadas

Pode envolver a seleção de subconjuntos limpos dos dados, a inserção de padrões adequados ou técnicas mais ambiciosas, como a estimativa de dados ausentes por modelagem

Preparação dos Dados

Derirvar dados

- Operações derivativas de preparação de dados, como a produção de atributos derivados, novos registros completos ou valores transformados para atributos existentes

Integrar dados

- Métodos pelos quais as informações são combinadas de várias tabelas ou registros para criar novos registros ou valores

Formatar os dados

Transformações de formatação referem-se principalmente a modificações sintáticas feitas nos dados que não alteram seu significado, mas podem ser exigidas pela ferramenta de modelagem

Modelagem

Selecione a técnica de modelagem (com base no objetivo de mineração de dados) Ex.: Modelagem Estatística, Modelagem para Machine Learning.
Construir modelo(Configurações de parâmetros)
Avalie o modelo (classifique os modelos)

Várias técnicas de modelagem são selecionadas e aplicadas e seus parâmetros são calibrados para valores ótimos. Algumas técnicas têm requisitos específicos na forma de dados. Portanto, muitas vezes é necessário voltar à fase de preparação de dados.

Modelagem

Construir modelo

- Execute a ferramenta de modelagem no conjunto de dados preparado para criar um ou mais modelos

Avaliar modelo

- Interpretar os modelos de acordo com seu conhecimento de domínio, os critérios de sucesso da mineração de dados e o design de teste desejado
- Julgar o sucesso da aplicação de técnicas de modelagem e descoberta de forma mais técnica
- Contatar analistas de negócios e especialistas de domínio posteriormente para discutir os resultados da mineração de dados no contexto de negócios
- Considerar apenas modelos enquanto a fase de avaliação também leva em conta todos os outros resultados que foram produzidos no decorrer do projeto

Avaliação

Avaliar os resultados

- Avalia o grau em que o modelo atende aos objetivos de negócios
- Procurar determinar se há algum motivo dentro do negócio para que esse modelo seja deficiente (análise crítica)
- Testar o(s) modelo(s) em aplicativos de teste no aplicativo real (simulações) se as restrições de tempo e orçamento permitirem
- Também avaliar outros resultados de mineração de dados gerados
- Revelar desafios adicionais, informações ou dicas para direções futuras

Avaliação

Processo de revisão

- Fazer uma revisão mais completa dos resultados de mineração de dados para determinar se há algum fator ou tarefa importante que de alguma forma foi negligenciado
- Revisar os problemas de garantia de qualidade ex. “Construímos o modelo corretamente?”

Definir os próximos passos

- Decidir como proceder nesta fase
- Decidir se deve **terminar o projeto e passar para a implantação**, se apropriado, ou se deve iniciar outras iterações ou configurar novos projetos de mineração de dados
- Incluir análises de recursos remanescentes e orçamento que influenciam as decisões

Implantação

Entende-se como IMPLANTAÇÃO as ações derivada dos resultados do projeto de DM. Ex. Ação de Marketing específica para o público feminino entre 20 e 30 anos,

Implantação do plano

- Para implantar o(s) resultado(s) da mineração de dados no negócio, pega os resultados da avaliação e conclui uma estratégia de implantação
- Documentar o procedimento para implantação posterior

Plano de monitoramento e manutenções

- Importante se os resultados da mineração de dados se tornarem parte do dia-a-dia dos negócios e do ambiente de TI
- Ajuda a evitar períodos desnecessariamente longos de uso incorreto de resultados de mineração de dados
- Precisa de um processo de monitoramento detalhado
- Levar em consideração o tipo específico de implantação

Implantação

Produzir relatório final

- O líder do projeto e sua equipe escrevem um relatório final
- Pode ser apenas um resumo do projeto e suas experiências
- Pode ser uma apresentação final e abrangente do(s) resultado(s) da mineração de dados

Rever o Projeto (Lições Aprendidas)

- Avaliar o que deu certo e o que deu errado, o que foi bem feito e o que precisa ser melhorado

CRISP - DM

Conclusões?
Dúvidas?
Certezas?
Obrigado!!!